

UNIVERSIDAD CARLOS III DE MADRID

APRENDIZAJE AUTOMÁTICO

COMPUTER SCIENCE ENGINEERING

Tutorial 2: Introducción a Weka

Authors:

Daniel MEDINA GARCÍA

Alejandro RODRÍGUEZ SALAMANCA

February 22, 2016

Contents

1	Los ficheros de datos	2
2	Clasificar con ZeroR	3
3	Generando nuevos atributos	4
4	Clasificar con ID3: resolviendo problemas	5
5	Clasificar con J48 (C4.5)	7
6	Utilizando más atributos con J48 (C4.5)	8
7	Balanceado de datos, selección de características y otros filtros	9

1 Los ficheros de datos

¿Cuántos atributos de entrada tiene el fichero de datos? ¿De qué tipo son?

- | | |
|---------------------------|---|
| <code>badges</code> | Este archivo contiene un atributo de entrada de tipo String que se corresponde con un nombre, y un atributo de salida, la clase a la que pertenece. |
| <code>badges_plain</code> | El contenido de este archivo es el mismo que el de <code>badges</code> , con la diferencia de que los nombres están previamente enumerados. |

¿Podría un algoritmo de aprendizaje automático identificar esa función con los datos que hay en ese fichero? ¿Por qué?

No. El fichero contiene tan solo un campo de datos, de tipo enumerado, y cada posible valor de dicho campo sólo se encuentra en una instancia. Al ser una clase con dos valores (muchos menos que valores del enumerado) y ser todas las instancias distintas, toda información que saque un algoritmo de aprendizaje automático será meramente memorización, sin valor alguno en futuras instancias con valores distintos a los actuales ya que no existe razonamiento o computación en la resolución de la clase.

2 Clasificar con ZeroR

¿Qué resultado en términos de instancias correctas ofrece el algoritmo ZeroR?

ZeroR indica un resultado del 51.0204% de instancias correctas. Lo único de lo que nos informa este dato es de que las clases están equilibradas dentro de nuestro conjunto de datos.

¿Qué ocurre si se selecciona otro algoritmo de clasificación permitido para ese conjunto de datos?

Utilizando meta / MultiScheme obtenemos exactamente el mismo resultado que con ZeroR. Esto es lógico pues no se puede mejorar el resultado al carecer de información suficiente para razonar sobre los datos.

¿Cuáles son las diferencias al repetir los pasos anteriores con el otro fichero, badges_plain?

Los mismos, pues aunque cambiemos el tipo de campo de enumerado a String se sigue sin tener información para razonar sobre los datos.

¿Qué ocurre si seleccionamos el algoritmo trees / ID3 en el segundo fichero?

Si probamos con ID3 podemos observar que el porcentaje de instancias correctamente clasificadas es del 100%. Si usásemos validación cruzada seguramente los resultados se parecerían más a los obtenidos con ZeroR, ya que se sigue sin tener información para clasificar más allá de la memorización y por ello no se tiene un criterio razonado para clasificar nuevas instancias.

3 Generando nuevos atributos

Propón 6 nuevos atributos y explica por qué los has elegido.

Al tener como datos de entrada nombres propios, sólo podemos basarnos en la naturaleza de las palabras que los componen para realizar algún tipo de razonamiento. Así, proponemos algunos nuevos campos a partir del original que detallan las características de dichos nombres:

- Número de letras del nombre.
- Número de vocales.
- Número de consonantes.
- Número de espacios.
- Inicial del nombre o del apellido.
- Número de repeticiones de cada una de las letras que aparecen.

¿Cuántos atributos tiene el fichero badges1 y de qué tipo son?

Este archivo contiene atributos que persiguen lo mismo que planteábamos en la pregunta anterior: descubrir más datos sobre los nombres. Así, el archivo contiene siete nuevos campos de entrada además del nombre de tipos numérico y enumerado.

¿Qué otro tipo de información estadística se muestra sobre los atributos? Tras pulsar el botón “Visualize all” indica qué se muestra y si hay algún atributo que no se visualice.

En cuanto a la información estadística sobre los atributos, si el atributo es de tipo nominal, aparece el valor y las veces que está repetido. En cambio, si es de tipo numérico, Weka nos ofrece el máximo, el mínimo, la media y la desviación estándar.

“Visualize all” muestra la correlación entre los valores para cada atributo y su pertenencia a una u otra clase.

Genera un clasificador con ZeroR, ¿qué ocurre? Compara los resultados con los obtenidos en el ejercicio anterior.

ZeroR es un clasificador que sólo tiene en cuenta el número de instancias que pertenecen a cada clase. Es por eso que su éxito al clasificar no varía respecto al anterior conjunto de datos que no ofrecía información.

Genera un clasificador con trees / ID3, ¿qué ocurre? ¿Qué se podría hacer para solucionar este problema?

No es posible generar un clasificador con ID3 porque ID3 no acepta datos del tipo numérico. Así, una posible solución sería convertir el tipo de entradas a otros tipos de atributo que no sean numerales (discretización).

4 Clasificar con ID3: resolviendo problemas

¿Qué información aparece en el desplegable tras abrir la pestaña *Capabilities* de ZeroR? ¿Qué información proporciona “more”?

En el desplegable aparecen los tipos de clase y de atributos que acepta el algoritmo. Además, indica como información “Adicional” el hecho de que ZeroR no tiene un número mínimo de entradas para su funcionamiento.

“more” muestra información no funcional sobre el algoritmo. Incluye el identificador unívoco del algoritmo dentro de Weka, una breve sinopsis explicando cómo trabaja dicho algoritmo y sus posibles opciones de configuración.

Los atributos de entrada pueden modificarse a través de tareas de preprocesamiento. En los siguientes pasos vamos a modificar ciertos atributos de *badges1* para que pueda clasificarse con ID3.

¿Qué efecto tiene el filtro de discretización sobre el conjunto de datos con *bins* igual a 5?

Discretiza, i.e. separa los valores de un atributo con valores continuos en su pertenencia a un rango determinado, los atributos previamente de carácter numérico convirtiéndolos en enumerados con tantos valores distintos como rangos creados. Creará tantos rangos como le fijemos a través de *bins*.

¿Cuántas instancias clasifica bien ahora ID3 usando un conjunto de entrenamiento? ¿Qué porcentaje representa? ¿Qué crees que indica la “matriz de confusión”? ¿Cuántas instancias de cada tipo se han clasificado mal?

ID3 clasifica bien 284 de 294 instancias con *bins* igual a 10, lo que supone un 96.5986% de éxito. Tras reducir *bins* a 5, clasifica correctamente 48 instancias menos (236 de 294), resultando en un 80.2721% de precisión. En ambos casos es un resultado considerablemente superior al obtenido con ZeroR, lo que nos indica que el algoritmo ha conseguido razonar sobre la información de los atributos para clasificar.

La matriz de confusión desglosa el éxito en la clasificación por cada una de las clases, y nos deja ver que han sido 9 las instancias erróneamente clasificadas como pertenecientes a la clase negativa mientras que tan sólo una instancia fue malinterpretada como positiva.

¿Cuál es la primera instancia del conjunto de entrenamiento que se clasifica mal cuando se usa la opción de mostrar las predicciones en la salida? ¿Por qué?

La séptima, ya que su clase es negativa y nuestro algoritmo la ha clasificado como positiva con un 57.1% de probabilidad. La opción marcada hace imprimir una tabla con tantas filas como instancias a clasificar, y los siguientes campos:

<i>inst#</i>	ID de la instancia.
<i>actual</i>	Clase a la que realmente pertenece la instancia.
<i>predicted</i>	Resultado de la clasificación de nuestro algoritmo.
<i>error</i>	Aparecerá un ‘+’ si la instancia fue erróneamente clasificada.
<i>prob. distr.</i>	Porcentaje de seguridad, para cada clase, de la pertenencia de la instancia a dicha clase.

¿Cómo se clasificaría la instancia “Eloisa Figueroa”? ¿Cuáles son los atributos de este nombre? ¿Qué ocurre con los valores de esta instancia si utilizas el filtro usado anteriormente?

Siguiendo el árbol, como el nombre tiene una longitud entre 14.2 y 17.8 (15), menos de 1.4 espacios (1) y menos de 10.8 consonantes (5), la instancia sería clasificada como negativa.

Otros campos no utilizados son la paridad y la primera letra vocal, de fácil deducción con valores 0 y 1 respectivamente, la inclusión de puntos en el nombre (0) y el número de palabras (2).

Si nos fijamos en el reparto de instancias por clase dentro de un mismo valor para los atributos recién mencionados podemos observar cómo el porcentaje de cada clase ronda el 50%, lo que indica que estos campos no añaden información para el algoritmo, ocurriendo lo mismo con el número de espacios.

Por otro lado, la longitud sí parece jugar un papel importante en la decisión. Echando un breve vistazo al reparto de clases en los valores discretizados de la longitud, vemos que según crece la longitud del nombre encontramos más instancias pertenecientes a la clase negativa, mientras que los nombres más cortos tienen más probabilidades de pertenecer a la positiva. Parece haber una cierta correlación con el número de consonantes, pero esta no es tan clara.

A continuación modificamos el fichero original introduciendo el nombre anterior y clasificándolo como positivo, teniendo en cuenta que si contiene enumerados y se introduce un nuevo valor hay que especificarlo también en la definición de los valores posibles del enumerado. Después volvemos a generar el clasificador con ZeroR y training set seleccionado.

¿Cómo se clasifica la instancia nueva?

Al haber una ligera mayoría de instancias positivas, ZeroR elige la positiva como la clase dominante. Así, la nueva instancia es clasificada correctamente como positiva.

5 Clasificar con J48 (C4.5)

¿Cuántas hojas tiene el árbol para badges1 generado con J48 usando conjunto de entrenamiento? ¿Cuántas instancias del conjunto de entrenamiento clasifica bien? ¿Qué porcentaje representa? ¿Cuántas instancias de cada tipo se han clasificado mal? ¿Cómo se clasificaría la instancia “Eloisa Figueroa”?

El árbol generado con J48 tiene 20 hojas. Este árbol clasificada correctamente 287 instancias, que equivale a un 97.619%. Las instancias incorrectamente clasificadas son 7, 3 en la clase negativa y 4 en la clase positiva.

¿Elegirías este modelo o el generado por ID3? ¿Por qué?

Respuesta

¿Hemos encontrado la función exacta para generar las etiquetas? ¿Por qué lo sabes?

Respuesta

6 Utilizando más atributos con J48 (C4.5)

Es momento de volver a la pestaña de preproceso y generar un nuevo atributo que calcule el número de vocales. Después se grabará el conjunto de datos como `badges1-2`, y con él se construirá un clasificador con J48. Una vez generado, se anotan el porcentaje de instancias bien clasificadas y la matriz de confusión, tras lo cual visualizaremos el árbol generado.

¿Qué indican los números que aparecen en las hojas del árbol?

Respuesta

¿Qué efecto tiene aumentar el valor de “Jitter” en la gráfica que relaciona el nuevo atributo con la clase?

Respuesta

¿Podrías decir cuál es el rango de vocales más común en el fichero proporcionado?
¿Se te ocurre algún otro atributo relacionado que pueda aportar información?

Respuesta

Tras todos estos resultados, ¿qué características o cualidades crees que deben tener los atributos para maximizar el éxito de los algoritmos de aprendizaje automático?

Respuesta

7 Balanceado de datos, selección de características y otros filtros

Para este apartado se carga en Weka `adult-data`.

¿Cuántos atributos de entrada tiene este fichero? ¿Cuántas instancias de entrenamiento?

Respuesta

¿Qué resultados aparecen ejecutando ZeroR con validación cruzada? Explica el resultado.

Respuesta

¿Qué resultados aparecen sólo con las instancias del fichero `adult-test.arff`? ¿Son estos resultados comparables a los anteriores? ¿Por qué?

Respuesta

¿Qué resultados aparecen repitiendo el proceso con J48? ¿Qué porcentaje de mejora ha obtenido respecto a los resultados del ZeroR?

Respuesta

¿Qué proporción de datos hay de cada clase? ¿Crees que este porcentaje es apropiado para que un algoritmo de aprendizaje automático aprenda bien?

Respuesta

¿Qué ocurre con el atributo de salida cuando se modifican las instancias de entrenamiento para tener un porcentaje similar entre las dos clases? ¿Ha descendido el número de ejemplos de entrenamiento?

Respuesta

Tras aplicar este filtro, se evalúan de nuevo con validación cruzada y `supplied test set` los algoritmos ZeroR y J48.

¿Qué resultados dan los algoritmos? ¿Qué resultado crees que es mejor? ¿Por qué?

Respuesta

¿Qué atributos consideras inútiles para el algoritmo de aprendizaje y por qué? Elimina un par de ellos. ¿Qué es lo que ocurre al repetir la evaluación anterior?

Respuesta

¿Qué resultados se obtienen aplicando el filtro de normalización para los atributos numéricos?

Respuesta

Después del procesamiento de datos que has realizado en este apartado, ¿crees que esto ayuda al proceso de aprendizaje? ¿Por qué? ¿Cuál es el mejor resultado obtenido? Justifícalo.

Respuesta